


第二章：词法分析

词法分析的基本功能
正则表达式

编译程序的组成



一、词法分析的基本功能

- ◆ 词法分析程序是编译程序的一部分，是整个编译过程的第一步工作。
- ◆ 词法分析程序的作用：
 - 扫描源程序的字符序列
 - 按照源语言的词法规则识别出各类单词
 - 产生用于语法分析的Token序列
 - 词法错误检查

◆ 词法分析器的任务：


分离单词，生成Token，检查词法错误

```
int main( )  
{ int x1;  
  x1= 1;  
  if( x1>0 )  
    x1=x1+10;  
}
```

- **单词：**是具有独立含义的**最小的语义单位**。（抽象的）
- **Token：**单词的具体表示（数据结构）
 - Token中应包含的信息没有统一的规定，可有不同的设计
 - 通常包含两类信息：<单词类别，单词内容>
 - 或者三类信息：<行号，单词类别，单词内容>

单词类型的划分

(! 基于语义，而非构成)



单词类型的划分

常用程序设计语言的单词可以分为以下几类：

- ◆ **保留字：**保留字一般是由语言系统自身定义的，通常是由字母组成的字符串。如C语言中的int，if，for，do等等。保留字在语言中具有特定的意义，是编译程序识别各类语法成分的依据。
- ◆ **标识符：**用来标识程序中各个对象的名称。通常它们由用户定义，用来表示变量名、常量名、数组名、函数名和结构体域名等。

单词类型的划分


- ◆ **常量**：主要包括整型常量、实型常量、字符常量、字符串常量、布尔类型常量等。
- ◆ **特殊符号**：包括运算符、界限符和控制符（格式符）。
 - **运算符**是程序中表示算术运算、逻辑运算、字符运算、赋值运算的确定的字符或字符串。
如各类语言通用的+、-、*、/、<、>=、<=等。
 - **界限符**在语言中是作为语法上的分界符号使用的，如逗号、分号、单引号、花括号等。
 - **格式符**主要用于程序的格式控制，如回车、空格、TAB等。对程序的执行不起作用，因此经词法分析后，不再保留。

单词的描述与识别

- ◆ 正则表达式 (描述单词)

$((y|z)^*x(y|z)^*x)^*(y|z)^*$

- ◆ 自动机 (识别, 描述单词)



二、正则表达式

- ◆ 主要内容

1. 基本概念
2. 正则表达式的定义
3. 正则表达式的性质
4. 如何基于正则表达式描述单词
5. 正则表达式的局限性
6. 正则表达式的应用

1. 基本概念

(1). 字母表 (alphabet)

字母表是元素的非空有穷集合, 字母表中的一个元素称为该字母表的一个字母 (letter), 也可叫做符号 (symbol) 或者字符 (character)。

注意: 字母表具有非空性和有穷性。

◆ 字母表有时也称为符号表, 通常用 Σ 表示。

例如: $\Sigma = \{a, b, c, d\}$, $\Sigma = \{0, 1\}$,

$\Sigma = \{\text{男}, \text{女}\}$, $\Sigma = \text{ASCII}$

(2). 符号串

由字母表中的符号组成的任何有穷序列称为字母表上的符号串。一般用 α , β , $\dots$, x , y , z 表示。

ε 表示空串。对任一字母表 Σ , 都有 ε 是 Σ 上的符号串。

(3). 符号串连接

设 α 和 β 均是字母表 Σ 上的符号串, α 和 β 的连接是把 β 的所有符号顺次地接在 α 的所有符号之后所得到的符号串。记为: $\alpha \bullet \beta$, $\bullet$ 可省略, 即 $\alpha\beta$ 。

例如: 设 $\alpha = abc$, $\beta = de$, 则 α 和 β 的连接:

$$\alpha \bullet \beta = \alpha\beta = abcde$$

$$\alpha \bullet \varepsilon = \alpha$$

(4). 符号串的方幂

设 α 是字母表 Σ 上的符号串，把 α 自身连接 n 次得到的符号串 $\alpha\alpha\cdots\alpha$ (n 个 α)，称作符号串 α 的 n 次幂，记作 α^n 。

$$\alpha^1 = \alpha$$

$$\alpha^2 = \alpha\alpha$$

$$\alpha^3 = \alpha^2\alpha = \alpha\alpha^2 = \alpha\alpha\alpha$$

...

$$\alpha^n = \alpha^{n-1}\alpha = \alpha\alpha^{n-1} = \alpha\alpha\cdots\alpha \quad (n\uparrow\alpha)$$

$$\alpha^0 = \varepsilon$$

(5). 符号串集合

若集合A中的所有元素都是某字母表 Σ 上的符号串，则称A为该字母表上的符号串集合。一般用A, B, C表示。

注意：空集 $\emptyset$ 不同于空串集 $\{\varepsilon\}$ 。

(6). 符号串集的乘积

设A、B 是两个符号串集合，AB表示A与B的乘积，具体定义为：

$$AB = \{ xy \mid (x \in A) \wedge (y \in B) \}$$

例： 设 $A = \{ a, bc \}$, $B = \{ de, f \}$, 则：

$$AB = \{ ade, af, bcde, bcf \}, \text{ 注意: } AB \neq BA$$

$$BA = \{ dea, debc, fa, fbc \}$$

特别有：1、 $\emptyset A = A\emptyset = \emptyset$, 其中 $\emptyset$ 表示空集。

$$2、\{\varepsilon\}A = A\{\varepsilon\} = A$$

(7). 符号串集合的方幂

设A为符号串的集合，则称 A^i 为符号串集 A 的方幂。具体定义如下：

$$A^0 = \{ \varepsilon \}$$

$$A^1 = A$$

$$A^2 = AA$$

.....

$$A^n = A^{n-1}A = AAA\cdots A \quad (n\text{个})$$

例： $A = \{ a, b \}$ 则：

$$A^0 = \{ \varepsilon \}$$

$$A^1 = \{ a, b \}$$

$$A^2 = AA = \{ a, b \} \{ a, b \} = \{ aa, ab, ba, bb \}$$

$$\begin{aligned} A^3 = A^2A &= \{ aa, ab, ba, bb \} \{ a, b \} \\ &= \{ aaa, aab, aba, abb, baa, bab, bba, bbb \} \end{aligned}$$

.....

$$A^n = A^{n-1}A = AAA\cdots A$$

(8). 符号串集合的正闭包 A^+

设 A 是符号串集合，则称 A^+ 是符号串集合 A 的正闭包 $A^+=A^1 \cup A^2 \cup A^3 \dots \cup A^n \dots$

(9). 符号串集合的星闭包 A^*

设 A 是符号串集合，则称 A^* 是符号串集合 A 的星闭包 $A^*=A^0 \cup A^1 \cup A^2 \cup A^3 \dots \cup A^n \dots$

即 $A^* = A^0 \cup A^+$

2.1 基本概念

例: 设 $A = \{ab, cd\}$, 则 :

$A^+ = \{ab, cd, abab, abcd, cdab, cdcd, ababab, ababcd, \dots\}$

$A^* = \{\varepsilon, ab, cd, abab, abcd, cdab, cdcd, ababab, ababcd, \dots\}$

2. 正则表达式的定义

设 Σ 为字母表，在 Σ 上的正则表达式可递归定义如下：

- (1) ε 和 $\emptyset$ 是 Σ 上的正则表达式；
- (2) 对任何 $a \in \Sigma$, a 是 Σ 上的正则表达式；
- (3) 若 r, s 都是正则表达式，则 (r) 、 $r|s$ 、 $r \bullet s$ 、 r^* 、 r^+ 也是正则表达式；
- (4) 有限次使用上述三条规则构成的表达式，称为 Σ 上的正则表达式。

2. 正则表达式的定义

- ◆ 正则表达式的语义函数：给正则表达式赋予一种语义解释的函数。
- ◆ 不同的语义解释会使得正则表达式具有不同的语义，其操作结果也会不同。

例如，1+1这个表达式，不同语义解释所赋予表达式的含义和操作结果并不相同：

$$1 + 1 = \begin{cases} 2, & \text{被解释为算术运算时} \\ 1, & \text{被解释为逻辑运算时} \end{cases}$$

2. 正则表达式的定义

单词的本质是字符串。

在词法分析中，为了用正则表达式描述单词，我们用语义函数为正则表达式和字符串集合建立一种映射关系，使得正则表达式的语义被解释成字符串集合。

在词法分析中，正则表达式 e 根据语义函数解释所得到的符号串集合称为正则表达式 e 的**正则集**。

2. 正则表达式的定义

若设 e 、 e_1 、 e_2 为 Σ 上的正则表达式，则 e 所对应的正则集 $L(e)$ 取值如下：

1. 当 $e=\emptyset$ 时， $L(e) = \emptyset$;
2. 当 $e=\varepsilon$ 时， $L(e) = \{\varepsilon\}$;
3. 对于 Σ 中一个字符 a ，若 $e=a$ ，则 $L(e) = \{a\}$;
4. 当 $e=e_1 \bullet e_2$ 时， $L(e) = L(e_1)L(e_2)$;
5. 当 $e=e_1 | e_2$ 时， $L(e) = L(e_1) \cup L(e_2)$;
6. $L((e)) = L(e)$;
7. $L(e^*) = L(e)^*$;
8. $L(e^+) = L(e)^+$.

正则表达式示例 (1)

◆ $\Sigma = \{ a, b \}$.

正则表达式e	$L(e)$
1. a	{ a }
2. a b	{ a, b }
3. ab	{ ab }
4. (a b) (a b)	{ aa, ab, ba, bb }
5. a*	{ ϵ , a, aa, aaa, aaaa, ... }

正则表达式示例 (2)

◆ $\Sigma = \{ a, b \}$.

正则表达式 e

1. ab^*

2. $a(a|b)^*$

$$\begin{aligned} L(a(a|b)^*) &= L(a) L((a|b)^*) \\ &= L(a) (L(a|b))^* \\ &= \{a\} \{a, b\}^* \end{aligned}$$

$$\begin{aligned} L(ab^*) &= L(a) L(b^*) \\ &= \{a\} \{\epsilon, b, bb, bbb, \dots\} \end{aligned}$$

$L(e)$

Σ 上所有以a为首后跟任意多个
(包括0个) b的字符串集

Σ 上所有以a为首的字符串集

3. 正则表达式的性质

正则表达式的性质

- $+ = * > \bullet > |$
- $A \mid B = B \mid A$
- $A \mid (B \mid C) = (A \mid B) \mid C$
 $A (B \mid C) = (A B) \mid A C$
- $A (B \mid C) = A B \mid A C$
 $(A \mid B) C = A C \mid B C$
- $A^{**} = A^*$
- $A\varepsilon = \varepsilon A = A$

运算优先级

$|$ 的可交换性

$|$ 的可结合性

连接的可结合性

连接的可分配性

连接的可分配性

幂的等价性

同一律

例1

- ◆ 设字母表 $\Sigma = \{0, 1\}$ ，写出一个正则表达式使之表示 Σ 上的所有为2的倍数的二进制数集合。
 1. Σ 上定义的所有串的正则表达式为： $(1|0)^*$
 2. 则二进制数表示为： $1(1|0)^*|0$
 3. 其中能被2整除的数表示为： $1(1|0)^*0|0$

例2

- ◆ 设字母表 $\Sigma = \{0, 1\}$ ，写出一个正则表达式使之表示 Σ 上所有长度是偶数的串的集合。

1. 长度是偶数则为长度是2的串的若干倍，即长度是2的串的星闭包
2. $\Sigma = \{0, 1\}$ 上长度是2的串有 $\{00, 01, 10, 11\}$
则长度是偶数的串为 $\{00|01|10|11\}^*$
3. 化简为 $\{(0|1)(0|1)\}^*$
4. 能否写成 $\{(0|1)\}^*$?



例3

- ◆ 设字母表 $\Sigma = \{0, 1\}$ ，写出一个正则表达式使之表示 Σ 上所有以1结尾不含子串00的符号串：

1. $r = (01 \mid 1)^*$?  包含 ε 不符合要求
2. $r = (01 \mid 1)(01 \mid 1)^* = (01 \mid 1)^+$ 
3. $r = (01 \mid 1)^*1$?  缺少 01的情况

例4

- ◆ 设字母表 $\Sigma = \{a, b\}$ ，正则表达式 $r = a^*b^+$ ，则 r 所定义的符号串集合 $L(r) = ?$
 1. $L(r) = \{b, bb, bbb, \dots, ab, aab, aabb, aaab, aaabb, \dots\}$
 2. 文字表述： $\Sigma = \{a, b\}$ 上由任意多个连续 a 和连续 b 构成且至少有1个 b 的符号串（不严谨）
 3. 数学表述： $L(r) = \{a^n b^m \mid n \geq 0, m \geq 1\}$ （严谨）

4. 正则表达式如何描述单词

- ◆ 标识符: $L(L|D)^*$, 其中 $L=A|B|\dots|a|b|\dots|z$; $D=0|1|\dots|9$
- ◆ 常数
 1. 整数: $(+|-|\epsilon)(D_1D^*)|0$, 其中 $D_1=1|2|\dots|9$
 2. 实数: $(+|-|\epsilon)(D_1D^*|0).D^*$
- ◆ 特殊符号: 用枚举的方式来表示
 1. 保留字: `while|if|for|...`
 2. 运算符: `+|-|*|...`
 3. 分界符: `{|}|;|[|]|(|)|...`
 4. 控制符: `\t|\0|\n|...`

5. 正则表达式的局限性

- 正则表达式不能用于描述配对的结构

例： $\{\alpha c \alpha \mid \alpha \text{是字符} a \text{和} b \text{组成的任意串}\}$

无法用正则表达式表示，因为无法保证两边 α 是相同的）。

- 正则表达式不能用于描述嵌套的结构

例： $n \in AE$ ； $(AE) \in AE$ ； $AE + AE \in AE$

6. 正则表达式的应用

- ◆ 文本的查找、替换
- ◆ 手机中常用的号码地区识别软件
- ◆ 软件的安全检测
- ◆ 程序分析
- ◆ 网络爬虫

课后练习

- ◆ 设字母表 $\Sigma = \{x, y, z\}$ ，试定义正则表达式，使之表示：
 1. 包含偶数个 x 的所有符号串。
 2. 不包含连续两个 y 的所有符号串集合。

$((y|z)^*x(y|z)^*x)^*(y|z)^*$

$((x|z|yx|yz)^*(y|\varepsilon))$