

第二章：词法分析

自动机与正则表达式的相互转换
词法分析器的设计

1. 自动机与正则表达式的相互转换

- ❖ 正则表达式向自动机的转换
- ❖ 自动机向正则表达式的转换
- ❖ 相关的例子

1.1 正则表达式向自动机的转换

◆ 定理 1


对 Σ 上的每一个正则表达式 R ，存在一个 Σ 上的非确定有限自动机 M ，使得 $L(M) = L(R)$.

1.1 正则表达式向自动机的转换

- ◆ 构造方法


- **step1**: 首先构造此非确定有限自动机M的初始状态S和终止状态Z，由S发出指向Z的有向弧并标上标记正则表达式R.
- **step2**: 反复利用下述的替换规则对正则表达式R依次进行分解，直至状态转换图中所有有向弧上标记的符号都是字母表 Σ 上的元素或 ε 为止.




1.1 正则表达式向自动机的转换



1.1 正则表达式向自动机的转换

- ◆ 例：有正则表达式 $(a|b)^*aa$, 为之构造等价的 NFA.












当形如 “ a^* ” 出现在正则表达式中时，转换时易出现错误

当 “ a^* ” 是独立的正则表达式时，转换规则中 ϵ 边可省





当“ a^* ”并非独立的正则表达式时，转换规则中 ϵ 边不可省



ϵ 边可通过确定化转换算法消除

1.2 自动机向正则表达式的转换

- ◆ **定理2:** 对于字母表 Σ 上的非确定有限自动机 M ，存在 Σ 上的正则表达式 R ，使得 $L(R) = L(M)$ 。
- ◆ **注意:** 这里 M 也可以是DFA，因为DFA是NFA的一种特例。



1.2 自动机向正则表达式的转换

◆ 构造方法：

Step1: 在M的状态转换图中加入两个节点，一个是唯一的开始状态节点S, 另一个是唯一的终止状态节点Z . 从S出发用标有 ε 的有向弧连接到M 的所有初始状态节点上，从M 的所有终止状态节点用标有 ε 的有向弧连接到Z节点.


Step2: 反复利用下述的替换规则进行替换，直到状态转换图中只剩下节点S和Z，在S指向Z的有向弧上所标记的正则表达式就是所求的结果.



1.2 自动机向正则表达式的转换




1.2 自动机向正则表达式的转换

- ◆ 例 有如下图所示的NFA M , 试构造与之等价的正则表达式 r









1.3 相关的例子

- ◆ 给出与正则表达式 $(a|b)(c|d)^*(e|f)$ 等价的最简DFA




NFA:




◆ 转化成DFA:

		a	b	c	d	e	f
A	$\{0\}^+$	$\{1, 2, 3\}$	$\{1, 2, 3\}$				
B	$\{1, 2, 3\}$			$\{2, 3\}$	$\{2, 3\}$	$\{4\}$	$\{4\}$
C	$\{2, 3\}$			$\{2, 3\}$	$\{2, 3\}$	$\{4\}$	$\{4\}$
D	$\{4\}^-$						

DFA:



DFA:




◆ 最小化

$\{A, B, C\}$ $\{D\}$


$\{A\}$ $\{B, C\}$ $\{D\}$


最简DFA:



类型题

- 构造与正则表达式 $a((a|b)^*ab^*a)b$ 等价的最简DFA，要求给出中间转换步骤和结果





$\{S\}^+$

$\{A, F, D\}$

$\{A, F, D\}$

$\{F, E, D, G, C\}$

$\{F, D\}$

$\{F, E, D, G, C\}$

$\{F, E, B, D, G, C\}$

$\{F, G, D, C\}$

$\{F, D\}$

$\{F, E, D, G, C\}$

$\{F, D\}$

$\{F, E, B, D, G, C\}$

$\{F, E, B, D, G, C\}$

$\{F, G, Z, D, C\}$

$\{F, G, D, C\}$

$\{F, E, B, D, G, C\}$

$\{F, G, D, C\}$


$\{F, G, Z, D, C\}^*$

$\{F, E, B, D, G, C\}$


$\{F, G, D, C\}$

确定化结果

	a	b
0^+	1	
1	2	3
2	4	5
3	2	3
4	4	6
5	4	5
6 *	4	5



最小化结果



2. 词法分析器的设计


词法分析器的设计步骤如下：

- ❖ 确定手工编写还是自动生成词法分析程序
- ❖ 确定词法分析器与语法分析器的接口
- ❖ 确定单词的种别
- ❖ 确定Token的结构
- ❖ 给出单词的描述
- ❖ 设计算法

2.1 词法分析器与语法分析器的接口

词法分析作为独立的一遍：

词法分析程序的输出放在一个中间文件中，
语法分析程序从该文件读取Token



简化了编译器的设计，使语法分析的逻辑更清晰；
可在读取字符和处理Token上进一步优化，提升效率

2.1 词法分析器与语法分析器的接口

词法分析作为语法分析的子程序：

每当语法分析程序需要单词时，就调用词法分析程序，使之输出一个Token供语法分析使用



避免了中间文件，省去了取送符号的工作，提升效率

2.2 确定单词的种别

- ◆ 不同程序设计语言，单词的种类及其构成会稍有差别
 - 关键字是否保留？
 - 标识符
 - 常量
 - 运算符
 - 分隔符/界限符

2.3 Token的结构

- ◆ 词法分析程序作为编译程序的第一步工作，其作用不仅需要识别出单词，还需要为后续编译工作提供信息。所以识别出的每个单词要以Token的形式记录下来。
- ◆ 关于Token的结构没有统一的规定，但至少应包含下面两部分内容：

单词的种别（语法信息）

单词的内容（语义信息）

单词种别

Token结构

保留字

一个保留字作为一类, 类别就代表了内容(if,-),
(void,-),(char,-)

所有保留字作为一类, 用内容区分不同的保留字
(rev,if),(rev, void),(rev, char)

标识符

所有标识符作为一类, 用内容区分不同的标识符
(id,x),(id, y2)

常量

所有常量作为一类, 也可按常量类型分类
(intC,1000),(realC,3.14),(boolC,true)

运算符

每个运算符作为一类, (plus-op,-),(mult-op,-),
(and-op, -), 也可按运算符类型分类

界限符

每个界限符作为一类, (comma,-),(open-
bracket,-)

一种可行的Token样例

Token结构

种别	内容
----	----

✓ 如果单词为标识符，则种别填1

1	
---	--

✓ 如果单词为常量，则种别填2

内容填其在相应索引表中的位置

2	
---	--

✓ 如果单词为保留字或特殊符号，则种别填该保留字或特殊符号所对应的数字

内容填 '空'

4	空
56	空

标识符索引表

1	x
...	...
n	sum

常量索引表

1	10
...	...
n	'a'

保留字表

3	while
4	if
...	...

特殊符号表

...	...
56	+

随词法分析进行而建

事先建好

例子

保留字表

3	while
4	if
5	for
6	void
7	...
...	...

有程序: if (x>10) y=x;

Token序列为:

<4,->,<15,->,<1,1>,<17,-><2,1>
<16,->,<1,2>,<18,->,<1,1>,<19,->

特殊符号表

15	(
16	)
17	>
18	=
19	;
...	...


标识符索引表

1	x
2	y
...	...

常量索引表

1	10
...	...

2.4 词法分析器的工作过程



根据词法分析器的工作流程可以将词法分析器的实现分为两部分：

- ◆ 单词的DFA描述及实现
- ◆ 针对不同的单词生成对应的Token

针对不同的单词生成对应的Token

- ◆ 标识符（保留字）的Token生成

首先查找保留字表，判断这个字符串是否为保留字，若是且编号为 n ，则生成保留字对应Token: $(n, -)$ ，不是则继续查找标识符索引表，确定其在标识符索引表中的位置 p ，生成该标识符对应的Token: $(1, p)$ 。

- ◆ 常量的Token生成

查找常量索引表，确定其在常量索引表中的位置 p ，生成该常量对应的Token: $(2, p)$ 。

- ◆ 特殊符号的Token生成

查特殊符号表，确定这个特殊符号在表中的类型编码 m ，生成该特殊符号对应的Token: $(m, -)$

2.5 词法分析时要注意的问题

- ◆ 保留字的识别
- ◆ 复合单词的识别
- ◆ 数的转换
- ◆ 向前看若干个字符
- ◆ 控制字符的处理
- ◆ 注释的处理

词法分析总结

- ◆ 这一章的内容需要掌握的是以下几点：
- ❖ 一个核心：词法分析器的设计
- ❖ 两个工具：正则表达式和自动机
- ❖ 三个转换算法：NFA到DFA，自动机的极小化，正则表达式和自动机的互相转换

课后练习

- ◆ 自定义一种Token结构，试写出下面C程序经过词法分析输出的Token序列
- ◆ `int main()`
- ◆ `{`
`float sum,first,count;`
`sum=first+count*10.01;`
`return 0;`
- ◆ `}`