

第三章：语法分析

文法与语言
文法分类
文法的相关概念

语法分析

- ◆ 语法分析是编译过程的核心部分
- ◆ 语法分析的基本任务是在词法分析识别出单词序列的基础上，分析判断程序的语法结构是否符合语言的语法规则
- ◆ 语言的语法结构用上下文无关文法来描述，因此语法分析程序的任务是按照上下文无关文法的产生式，判断整个单词序列是否构成语法上正确的程序
 - 自顶向下的语法分析(top-down)
 - 自底向上的语法分析(bottom-to-up)

一、文法与语言

- ◆ 文法(Grammar)是程序语言的生成系统。用文法可精确定义一个语言，并依据文法构造出识别该语言的自动机。因此，文法对程序设计语言和编译程序的构造具有重要意义。
- ◆ 程序语言的词法可用正则文法（正则表达式，有限自动机）描述，语法可用上下文无关文法描述，语义可用上下文有关文法描述。
- ◆ 文法的产生：自然语言与程序语言的区别
“去哪儿？” “if (x>0) y++ else y--;”
- ◆ 语言的三个基本要素：语法、语义、语用

1.1 语言

- ◆ Σ 表示字母表。由字母表 Σ 中字符组成的有穷序列称为 Σ 上的字符串或字。字母表 Σ 上的所有字符串（包括空串）组成的集合用 Σ^* 表示。
- ◆ 对于字母表 Σ ， Σ^* 上的任一子集称为 Σ 上的一个语言，记为 L ， $L \subset \Sigma^*$ 。语言 L 中的每个字符串称为语言 L 的一个语句或句子。

1.2 文法

一个文法G是一个四元组: $G = (V_T, V_N, S, P)$ 其中:

- V_T (*Terminal Vocabulary*) 是一个非空的有限集合, 它的每个元素称为终极符号或终极符, 一般用小写字母表示。从语法分析的角度看, 终极符号是一个语言不可再分的基本符号。 (每个Token就是一个终极符)
- V_N (*Nonterminal Vocabulary*) 是一个非空的有限集合, 它的每个元素称为非终极符号、非终极符或中间符, 一般用大写字母表示。非终极符是一个语法范畴, 表示一类具有某种性质的符号。
注: 设V是文法G的符号集, 则有: $V = V_N \cup V_T, V_N \cap V_T = \emptyset$
- S (*Start*) 是特殊的非终极符号, 称为文法的开始符号, $S \in V_N$ 。
- P (*Production*) 是产生式的有限集合。所谓的产生式, 也称为产生规则 (简称为规则), 是按照一定格式书写的定义语法范畴的文法规则。

- ◆ 产生式（也称产生式规则或规则）是定义语法实体的一种书写规则，形式为 $\alpha \rightarrow \beta$ 或 $\alpha ::= \beta$ ，其中
- ◆ “ $\rightarrow$ ” 或 “ $::=$ ” ：读作“定义为”或“由...组成”
- ◆ $\alpha \in (V_T \cup V_N)^+$ ，且至少含一个非终极符，称为产生式的左部(头)。特别地，当所有产生式的左部都只有一个符号时，即所有产生式都形如 $A \rightarrow \beta$ 的文法，称为上下文无关文法。用上下文无关文法描述程序语言的语法。
- ◆ $\beta \in (V_T \cup V_N)^*$ ，称为产生式的右部（体）
- ◆ 开始符号 S 必须至少在某个产生式的左部出现一次，如无特别指定，第一条产生式左部的符号看作开始符
- ◆ 当某个语法实体 P 对应多条产生式时，如，

$$P \rightarrow \alpha_1 \quad P \rightarrow \alpha_2 \quad \dots \quad P \rightarrow \alpha_n$$

多条产生式可以合并为一个， 写为：

$P \rightarrow \alpha_1 \mid \alpha_2 \mid \dots \mid \alpha_n$ ， 其中每个 α_i 称为 P 的一个候选式

文法的例子

- ◆ 写一个定义整数的文法：
- ◆ $G = \{V_T, V_N, S, P\}$ ，其中
$$V_T = \{0, 1, 2, \dots, 9\},$$
$$V_N = \{N, D\},$$
$$S = N,$$
$$P = \{N \rightarrow D, N \rightarrow ND, D \rightarrow 0 \mid 1 \mid \dots \mid 9\}$$

思考：1，上述文法是否可写成 $N \rightarrow D^+$

2，除整数0外，其他整数不允许以0开头，文法该如何改写？

文法的例子

- ◆ 标识符的文法:
- ◆ 分析: 用L表示字母, D表示数字, T表示字母或数字

则 $L \rightarrow a | b | \dots | z$

$D \rightarrow 0 | 1 | \dots | 9$

$T \rightarrow L | D$

用S表示字母或数字的串, 则

$S \rightarrow T | ST$

用I表示标识符, 则

$I \rightarrow L | LS$

G: $\{\{a,b,\dots,z,0,\dots,9\}, \{I, S, T, L, D\}, I, \xi\}$,

其中 ξ : $I \rightarrow L | LS$

$S \rightarrow T | ST$

$T \rightarrow L | D$

$D \rightarrow 0 | 1 | \dots | 9$

$L \rightarrow a | b | \dots | z$

文法的例子

- ◆ 标识符的文法：另一种思路
- ◆ 分析：用L表示字母，D表示数字，I表示标识符
则 $L \rightarrow a|b|\dots|z$
 $D \rightarrow 0|1|\dots|9$
 $I \rightarrow L \mid IL \mid ID$

G: $\{\{a,b,\dots,z,0,\dots,9\}, \{I, L, D\}, I, \xi\}$, 其中 ξ :

$$I \rightarrow L \mid IL \mid ID$$
$$D \rightarrow 0|1|\dots|9$$
$$L \rightarrow a|b|\dots|z$$

1.3 文法产生的语言

- ◆ 设文法 $G = \{V_T, V_N, S, P\}$ ，且 $\alpha, \beta \in (V_T \cup V_N)^*$ ，若存在产生式 $A \rightarrow \delta$ ， $\delta \in (V_T \cup V_N)^*$ ，则称 $\alpha A \beta$ 可直接推导出 $\alpha \delta \beta$ ，记为 $\alpha A \beta \Rightarrow \alpha \delta \beta$ 。
- ◆ 注意： $\Rightarrow$ 与 $\rightarrow$ 不同！！！！
- ◆ $\rightarrow$ 是产生式中的定义符号，
- ◆ $\Rightarrow$ 表示直接推导，是对文法符号串 $\alpha A \beta$ 中的非终极符 A ，用产生式 $A \rightarrow \delta$ 右部的符号串 δ 替换。

1.3 文法产生的语言

- ◆ 若 $\alpha_1 \Rightarrow \alpha_2, \alpha_2 \Rightarrow \alpha_3, \dots$,
即存在一个自 α_1 至 α_n 的直接推导序列:
$$\alpha_1 \Rightarrow \alpha_2 \Rightarrow \alpha_3 \Rightarrow \dots \Rightarrow \alpha_n (n > 1)$$

则称 α_1 可推出 α_n , 记为 $\alpha_1 \Rightarrow^+ \alpha_n$,
表示从 α_1 出发经 1 步或若干步可推导出 α_n 。
- ◆ 相应地, 用 $\alpha_1 \Rightarrow^* \alpha_n$ 表示从 α_1 出发经 0 步或若干步可推导出 α_n 。即 $\alpha_1 \Rightarrow^* \alpha_n$ 意味着 $\alpha_1 = \alpha_n$ 或 $\alpha_1 \Rightarrow^+ \alpha_n$

- ◆ 设有算术表达式文法G如下：

- ◆ $E \rightarrow E + E \mid E * E \mid (E) \mid i$

- ◆ 非终极符E代表一类算术表达式，

- ◆ 从E出发可产生一系列推导，

- ◆ 表达式 $i + i * i$ 的推导如下：

- ◆ $E \Rightarrow E + E \Rightarrow E + E * E \Rightarrow i + E * E \Rightarrow i + i * E \Rightarrow i + i * i$

- ◆ 也可以是下面的推导：

- ◆ $E \Rightarrow E * E \Rightarrow E * i \Rightarrow E + E * i \Rightarrow i + E * i \Rightarrow i + i * i$

- ◆ 当然，还有其他的推导序列

- ◆ 同时要注意，每步推导只能对其中的一个非终极符使用产生式的右部进行替换


1.3 文法产生的语言

- ◆ 句型：设有文法 G ， S 是其开始符，如果有 $S \Rightarrow^* \beta$ ， $\beta \in (V_T \cup V_N)^*$ ，则称符号串 β 为 G 的句型。
- ◆ 开始符 S 是 G 的一个句型
- ◆ 句子：设 β 为文法 G 的一个句型，且 β 只包含终极符，则称 β 为 G 的句子。
- ◆ 语言： $L(G) = \{ u \mid S \Rightarrow^+ u, u \in V_T^* \}$ 。文法 G 所定义的语言是其所有句子的集合。

例：对于表达式文法G:

$$E \rightarrow E + E \mid E * E \mid (E) \mid i$$

E 、 $E + E$ 、 $i + E$ 、 $i + E * E$ 、 $i + i * E$ 、 $i + i * i$
为G的句型。



1.3 文法产生的语言

- ◆ 每一种高级程序设计语言都有自己的文法
- ◆ 符合高级语言文法的程序就是该文法的句子
- ◆ 所有程序组成的集合就构成了语言

1.3 文法产生的语言

◆ PASCAL语言语法例子：

<程序> → <首部> <声明部分> <程序体>

<首部> → program (<运行环境>)

<声明部分> → <标号声明> <常量声明> <类型声明>
 <变量声明> <过程函数声明>

<标号声明> → ...

.....

<过程函数声明> → ...

<程序体> → begin <语句序列> end

<语句序列> → <语句> <语句序列> | <语句>

<语句> → <条件语句> | <循环语句> | <赋值语句> |
 <输入输出语句> | <过程调用语句> ...

1.4 验证程序是不是文法的句子

- ◆ 最基本的方法：采用类搜索算法，从开始符出发进行推导
- ◆ 用剪枝来提高效率


两种基本思想


- ◆ 自顶向下的语法分析：从开始符出发，根据定义看是否可以推导出程序。
- ◆ 自底向上的语法分析：从程序出发，用规则的左部替换规则的右部，一直到归约成开始符。

二、文法分类

- ◆ 1956年, 著名的语言学家乔姆斯基将文法分为四类:
- 0型文法 也称为短语文法(PSG), 其产生式具有形式:
 - $\alpha \rightarrow \beta$, 其中 $\alpha, \beta \in (V_T \cup V_N)^*$, 并且 α 至少含一个非终极符;
- 1型文法: 也称为上下文有关文法(CSG)。它是0型文法的特例。其产生式具有形式:
 - (1) $\alpha A \beta \rightarrow \alpha \gamma \beta, A \in V_N, \gamma \in (V_T \cup V_N)^+, \alpha, \beta \in (V_T \cup V_N)^*$. 或
 - (2) $|\alpha| \leq |\beta|$ (S 是开始符, $S \rightarrow \epsilon$ 除外, 且 S 不出现在任何产生式的右部)
- 2型文法: 也称为上下文无关文法(CFG)。它是1型文法的特例。其产生式具有形式:
 - $A \rightarrow \beta, A \in V_N, \beta \in (V_T \cup V_N)^*$. 即要求产生式左部是一个非终极符。
- 3型文法: 也称为正则文法(RG)。它是2型文法的特例。其产生式的右部至多有两个符号, 而且具有下面形式之一:
 - $A \rightarrow a, A \rightarrow a B$, 其中 $A, B \in V_N, a \in V_T$

二、文法分类





0型文法

1型文法

2型文法

3型文法

产生式限制越来越严

描述功能越来越强

二、文法分类

在编译技术中通常用3型文法（正则文法）来描述高级程序设计语言的词法部分，2型文法（上下文无关文法）描述的程序设计语言的语法结构，比如描述算术表达式，描述各种语句等等。

在后续课程中，对“文法”一词如无特殊说明则均指上下文无关文法。

三、文法的基本概念

- ◆ 最左（右）推导：

如果进行推导时选择的是句型中的最左（右）非终极符，则称这种推导为最左（右）推导，并用符号 $\Rightarrow_{lm}$ ($\Rightarrow_{rm}$) 表示最左（右）推导。

- ◆ 左（右）句型：

用最左推导方式导出的句型，称为左句型，而用最右推导方式导出的句型，称为右句型（规范句型）。

- ◆ 结论：

每个句子都有相应的最右和最左推导（但对句型此结论不成立）

- ◆ 考虑句子 $i+i*i$ 按文法 G 的推导
- ◆ 最左推导: $E \Rightarrow_{lm} E + E \Rightarrow_{lm} i + E \Rightarrow_{lm} i + E^* E$
 $\Rightarrow_{lm} i + i^* E \Rightarrow_{lm} i + i^* i$
- ◆ 最右推导: $E \Rightarrow_{rm} E + E \Rightarrow_{rm} E + E^* E \Rightarrow_{rm} E + E^* i$
 $\Rightarrow_{rm} E + i^* i \Rightarrow_{rm} i + i^* i$
- ◆ 推导过程不唯一, 通常只考虑最左推导或最右推导
- ◆ 最右推导又称规范推导, 规范推导产生的句型称为规范句型
- ◆ 规范推导的逆过程称为规范归约 (最左归约)

三、文法的基本概念

◆ 短语

设 S 是文法的开始符, 有 $S \Rightarrow^* \alpha A \delta$, 如果有 $A \Rightarrow^+ \beta$ 则称 β 是句型 $\alpha \beta \delta$ 关于 A 的一个短语。

◆ 简单短语

设 S 是文法的开始符, 有 $S \Rightarrow^* \alpha A \delta$, 如果有 $A \Rightarrow \beta$ 则称 β 是句型 $\alpha \beta \delta$ 关于 A 的一个简单短语 (直接短语)。

◆ 句柄

句型中的最左简单短语称为句柄。

注: (若文法无二义性) 一个句型的简单短语不一定唯一, 但句柄一定唯一

例：对于表达式文法G：

$$E \rightarrow E + E \mid E * E \mid (E) \mid id$$

$id * id$ 为句型 $id + id * id$ 的一个短语。

因为：

$$E \Rightarrow E + E \Rightarrow id + E$$

$$E \Rightarrow E * E \Rightarrow id * E \Rightarrow id * id$$

思考题： $id + id * id$ 亦为句型 $id + id * id$ 的一个短语。

例：对于表达式文法G：

$$E \rightarrow E + E \mid E * E \mid (E) \mid id$$

$id * id$ 不是句型 $id + id * id$ 的简单短语。

因为：

$$E \Rightarrow E + E \Rightarrow id + E$$

$$E \Rightarrow E * E \Rightarrow id * E \Rightarrow id * id$$

例：设有文法 $G[S]: S \rightarrow cAdBf$

$A \rightarrow ab \mid a$

$B \rightarrow e \mid eB$

考虑符号串 $\$ = cabdef$.

因： $S \Rightarrow cAdBf \Rightarrow cAdef$

$A \Rightarrow ab$

又因： $S \Rightarrow cAdBf \Rightarrow cabdBf$

$B \Rightarrow e$

所以： e, ab 分别为 $cabdef$ 的简单短语；
其中： ab 为 $cabdef$ 的句柄。

课后练习 (1)

- ◆ 写一文法使其语言是奇数集，但不允许出现以0开头的奇数。

G: $\{N, A, M, B, D\}, \{0, \dots, 9\}, N, \xi$,
其中 ξ :

$$N \rightarrow A \mid MA$$
$$A \rightarrow 1 \mid 3 \mid 5 \mid 7 \mid 9$$
$$M \rightarrow B \mid MD$$
$$B \rightarrow 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$$
$$D \rightarrow B \mid 0$$

课后练习 (2)

- ◆ 构造一个文法G, 使
 $L(G) = \{a^n b^m c^k \mid m = n + k, n \geq 1, m > 1, k \geq 1\}$

G[S] : $S \rightarrow AB$

$A \rightarrow aAb \mid ab$

$B \rightarrow bBc \mid bc$

课后练习 (3)

已知文法G的产生式规则如下：

$$E \rightarrow E+T \mid T$$
$$T \rightarrow T * F \mid F$$
$$F \rightarrow (E) \mid i \text{ (标识符)}$$

问：(T+i)*F+i 是不是文法G的句型？如果是，该句型有哪些短语，简单短语，句柄是哪个？

$$\underline{E} \Rightarrow \underline{E} + T$$

$$\Rightarrow \underline{T} + T$$

$$\Rightarrow \underline{T} * F + T$$

$$\Rightarrow \underline{F} * F + T$$

$$\Rightarrow (\underline{E}) * F + T$$

$$\Rightarrow (\underline{E} + T) * F + T$$

$$\Rightarrow (T + \underline{T}) * F + T$$

$$\Rightarrow (T + \underline{F}) * F + T$$

$$\Rightarrow (T + i) * F + \underline{T}$$

$$\Rightarrow (T + i) * F + i$$

◆ 短语

$(T+i)*F+i$, 是由E推导出来

$(T+i)*F$ 是由T推出来的

两个i ; $T+i$; $(T+i)$; T;

◆ 简单短语

T 两个i

◆ 句柄

T